

# Algorytmika

## Ćwiczenia 3

Adrian Herda

2025-06-28

$$\mu = E[X]$$

$$\sigma^2 = \text{Var}(X) = E[X^2] - E[X]^2$$

$$\sigma = \text{Std}(X) = \sqrt{\text{Var}(x)} = \sqrt{E[X^2] - E[X]^2}$$

### 1. Zadanie 12 - losowanie monetą

Rzucamy monetą dwa razy:

- $\Pr(\text{Orzeł}, \text{Reszka}) = p \cdot q$  – Orzeł monety normalnej
- $\Pr(\text{Reszka}, \text{Orzeł}) = q \cdot p$  – Reszka monety normalnej

Oba wyniki są sobie równe, jeśli będziemy ignorować wyniki (Orzeł, Orzeł) oraz (Reszka, Reszka), dostajemy monetę uczciwą.

$$\Pr(\text{Orzeł}) = \Pr(\text{Reszka}) = \frac{pq}{pq + pq} = \frac{1}{2}$$

### 2. Zadanie 13 - jednostajnie losowane $[0, \dots, 6]$

1. Mamy generator liczb losowych ze zbioru  $\{0, \dots, 4\}$ , niech wynik tego generatora będzie oznaczony literą  $X$ .
2. Tworzymy generator liczb losowych ze zbioru  $\{1, \dots, 24\}$

$$Y = 5a + b$$

gdzie  $a, b \in \{0, \dots, 4\}$  są generowane przez generator z punktu 1. Z tego wynika że:

$$\Pr(Y = y) = \Pr(Y = 5a + b) = \Pr(X = a) \cdot \Pr(X = b) = \frac{1}{5} \cdot \frac{1}{5} = \frac{1}{25}$$

3. Zbiór liczb  $\{0, \dots, 20\}$  ma  $3 \cdot 7$  liczb co pozwoli nam na dopasowanie równej ilości liczb do zbioru  $\{0, \dots, 6\}$  za pomocą operacji mod 7.
4. Jeśli  $Y > 20$  odrzucamy wynik i ponownie losujemy dwie liczby, powtarzamy dopóki nie wylosujemy  $Y \leq 20$ , w takim przypadku wylosowaną zmienną liczymy

$$Z = Y \bmod 7$$

i w ten sposób dostajemy liczbę ze zbioru  $\{0, \dots, 6\}$  z prawdopodobieństwem:

$$\forall_{z \in \{0, \dots, 6\}} \left( \Pr(Y \bmod 7 = z) = \frac{3}{25} \right) \implies \Pr(Z = z) = \frac{1}{7}$$

### 3. Zadanie 14 - pole koła z Monte Carlo

#### 3.1. Var(X)

Losujemy  $n$  punktów  $(x_i, y_i) \in [0, 1]^2$

Niech:

$$Z_i = \begin{cases} 1 & \text{jeśli } x_i^2 + y_i^2 \leq 1 \\ 0 & \text{w przeciwnym razie} \end{cases}$$

$$\left( \forall_{i \in [n]} \right) \left( \Pr(Z_i = 1) = \frac{\text{Area}_\circ}{\Omega} = \frac{\frac{\pi}{4}}{1 \cdot 1} = \frac{\pi}{4} \Rightarrow E[Z_i] = \frac{\pi}{4} \cdot 1 + \left(1 - \frac{\pi}{4}\right) \cdot 0 = \frac{\pi}{4} \right)$$

Mamy do czynienia z rozkładem Bernoulliego z prawdopodobieństwem wynoszącym tyle co pole ćwiartki koła czyli  $p = \frac{\pi}{4}$ . Zatem wiemy od razu że

$$\left( \forall_{i \in [n]} \right) \left( E[Z_i] = p = \frac{\pi}{4} \right)$$

oraz że

$$\left( \forall_{i \in [n]} \right) (\text{Var}(Z_i) = p(1 - p))$$

Wtedy pole:

$$A_n = \frac{1}{n} \sum_{i=1}^n Z_i$$

Wiemy że wybierane punkty są od siebie niezależne więc  $\left( \forall_{i, j \in [n], i \neq j} \right) (\text{Cov}(Z_i, Z_j) = 0)$ . Ze wzoru na wariancję z mnożnikiem stałym oraz ze wzoru na wariancję sumy zmiennych niezależnych:

$$\begin{aligned} \sigma_n^2 = \text{Var}(A_n) &= \text{Var}\left(\frac{1}{n} \sum_{i=1}^n Z_i\right) = \frac{1}{n^2} \text{Var}\left(\sum_{i=1}^n Z_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(Z_i) = \frac{1}{n^2} \cdot n \cdot p(1 - p) = \frac{p(1 - p)}{n} \\ &\Downarrow \\ \sigma_n^2 &= \frac{\frac{\pi}{4}(1 - \frac{\pi}{4})}{n} = \frac{\frac{\pi}{4} \cdot \frac{4 - \pi}{4}}{n} = \frac{4\pi - \pi^2}{16n} \end{aligned}$$

#### 3.2. Minimalne $n$ potrzebne do dokładności 0.01 z prawdopodobieństwem 0.99

Nierówność Czebyszewa:

$$\Pr(X \geq \varepsilon) \leq \frac{E[X]}{\varepsilon}$$

Z Treści zadania chcemy żeby  $\Pr(|A_n - E[A_n]| \geq 0.01) \leq 0.01$

$$\Pr(|A_n - E[A_n]| \geq 0.01) = \Pr(|A_n - E[A_n]|^2 \geq 0.01^2) \leq \frac{\sigma_n^2}{0.01^2}$$

$\Downarrow$

$$0.01 = \frac{\sigma_n^2}{0.01^2} = \frac{4\pi - \pi^2}{16n \cdot 0.01^2}$$

$\Downarrow$

$$n = \left\lceil \frac{4\pi - \pi^2}{0.01^3 \cdot 16} \right\rceil \approx \lceil 168547.888329363395938 \rceil = 168548$$

### 3.3. To samo ale z nierównością Chernoffa

Nierówność Chernoffa:

$$X = \sum_{i=1}^n Z_i$$

$$\mu_n = E[X] = \frac{n\pi}{4}$$

$$\Pr(|X - \mu_n| > \varepsilon \mu) \leq 2 \exp\left(-\frac{\varepsilon^2}{2 + \varepsilon} \mu\right)$$

Z treści zadania chcemy żeby  $\Pr(|A_n - E[A_n]| \geq 0.01) \leq 0.01$

$$\Pr(|A_n - E[A_n]| \geq 0.01) = \Pr\left(\frac{1}{n} |X - \mu_n| \geq 0.01\right) = \Pr(|X - \mu_n| \geq 0.01n) \leq 2 \exp\left(-\frac{\varepsilon^2}{2 + \varepsilon} \mu_n\right)$$

$$0.01n = \varepsilon \mu_n = \varepsilon \frac{n\pi}{4} \Rightarrow \varepsilon = \frac{0.04}{\pi}$$

$\Downarrow$

$$\frac{0.01}{2} = 0.005 = \exp\left(-\frac{\varepsilon^2}{2 + \varepsilon} \mu_n\right) = \exp\left(-\frac{\left(\frac{0.04}{\pi}\right)^2}{2 + \frac{0.04}{\pi}} \cdot \frac{n\pi}{4}\right) =$$

$$= \exp\left(-\frac{0.0016 \cdot n\pi}{\pi^2 \cdot \frac{2\pi + 0.04}{\pi} \cdot 4}\right) = \exp\left(-\frac{0.0016n}{8\pi + 0.16}\right) = e^{-\frac{0.0016n}{8\pi + 0.16}}$$

$\Downarrow$

$$-\ln(0.005) = \frac{0.0016n}{8\pi + 0.16} \Rightarrow (\pi + 0.02) \cdot \ln(0.005^{-1}) = 0.0002n$$

$\Downarrow$

$$n = \lceil (\pi + 0.02) \cdot \ln(200) \cdot 5000 \rceil \approx \lceil 83755.6063123274 \rceil = 83756$$

## 4. Zadanie 15 - Standardowe odchylenia przy obliczaniu ćwiartek koła

### 4.1. Metoda losowania z $[0, 1]^2$

Niech:

$$X_i = \begin{cases} 1 & \text{jeśli } x_i^2 + y_i^2 \leq 1 \\ 0 & \text{w przeciwnym wypadku} \end{cases}$$

Wtedy:

$$\begin{aligned}A_X &= \frac{1}{n} \sum_{i=1}^n X_i \\&\Downarrow \\ \sigma_X^2 &= \text{Var}(A_X) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \text{Var}\left(\sum_{i=1}^n X_i\right) = \\&= \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{1}{n^2} \cdot n \cdot \frac{\pi}{4} \left(1 - \frac{\pi}{4}\right) = \frac{\frac{\pi}{4} \left(1 - \frac{\pi}{4}\right)}{n} \\&\Downarrow \\ \sigma_X &= \sqrt{\frac{\frac{\pi}{4} \left(1 - \frac{\pi}{4}\right)}{n}} \approx \sqrt{\frac{0.1685}{n}} \approx \frac{0.4105}{\sqrt{n}}\end{aligned}$$

#### 4.2. Metoda losowania z $[0, 1]$

Niech:

$$\begin{aligned}Y_i &= \sqrt{1 - x_i^2} \\&\Downarrow \\ E[Y_i] &= \int_0^1 \sqrt{1 - x_i^2} dx = \frac{\pi}{4} \\ E[Y_i^2] &= \int_0^1 1 - x_i^2 dx = x - \frac{x_i^3}{3} \Big|_0^1 = 1 - \frac{1}{3} = \frac{2}{3} \\ \sigma_Y^2 &= E[Y_i^2] - E[Y_i]^2 = \frac{2}{3} - \left(\frac{\pi}{4}\right)^2 \approx 0.0498\end{aligned}$$

Wtedy:

$$\begin{aligned}A_Y &= \frac{1}{n} \sum_{i=1}^n Y_i \\&\Downarrow \\ \sigma_Y^2 &= \text{Var}(A_Y) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(Y_i) = \frac{1}{n^2} \sum_{i=1}^n \frac{2}{3} - \left(\frac{\pi}{4}\right)^2 = \frac{\frac{2}{3} - \left(\frac{\pi}{4}\right)^2}{n} \\ \sigma_Y &= \sqrt{\frac{\frac{2}{3} - \left(\frac{\pi}{4}\right)^2}{n}} \approx \sqrt{\frac{0.0498}{n}} \approx \frac{0.2232}{\sqrt{n}}\end{aligned}$$

#### 4.3. Wnioski

$$\sigma_X > \sigma_Y$$

Metoda losowania na jednej osi daje lepsze wyniki (o mniejszej wariancji) i zbiega do wartości oczekiwanej szybciej niż metoda losowania z dwóch osi

### 5. Zadanie 16

Niech:

$$X \in [0, 1]$$

$$Y = \begin{cases} X & \text{jeśli } X \in [\frac{1}{2}, 1] \\ 1 - X & \text{jeśli } X \in [0, \frac{1}{2}] \end{cases} \Rightarrow Y \in [\frac{1}{2}, 1]$$

Dystrybucja Y:

$$F_Y(y) = \Pr(Y \leq y) = \Pr(\max\{X, 1 - X\} \leq y) = \Pr(X \in [1 - y, y]) \text{ dla } y \in [\frac{1}{2}, 1]$$

Jako że X jest losowane z rozkładem jednostajnym to:

$$F_Y(y) = \frac{y - (1 - y)}{1} = 2y - 1 \text{ dla } y \in [\frac{1}{2}, 1]$$

Gęstość prawdopodobieństwa:

$$f_Y(y) = \frac{d}{dy} F_Y(y) = \frac{d}{dy} (2y - 1) = 2$$

$$\Downarrow$$

Y ma rozkład jednostajny  $\Rightarrow E[Y] = 0.75$

$$E[Y^2] = \int_{\frac{1}{2}}^1 y^2 \cdot f_Y(y) dy = \int_{\frac{1}{2}}^1 2y^2 dy = \left[ \frac{2y^3}{3} \right]_{\frac{1}{2}}^1 = \frac{2}{3} - 2 \cdot \frac{1}{8} \cdot \frac{1}{3} = \frac{8}{12} - \frac{2}{12} = \frac{6}{12} = \frac{1}{2}$$

$$\Downarrow$$

$$\sigma_Y^2 = E[Y^2] - E[Y]^2 = \frac{1}{2} - \left(\frac{3}{4}\right)^2 = \frac{2}{4} - \frac{9}{16} = \frac{8}{16} - \frac{9}{16} = -\frac{1}{16}$$

## 6. Zadanie 17

X ma rozkład jednostajny na  $[0, 1]$  więc:

$$f_X(x) = 1$$

$$E[X] = \frac{1}{2}$$

$$E[X^2] = \int_0^1 x^2 dx = \left[ \frac{x^3}{3} \right]_0^1 = \frac{1}{3}$$

$$\sigma_X^2 = \frac{1}{3} - \frac{1}{4} = \frac{1}{12}$$

$$\Downarrow$$

$$\text{Cov}(X, Y) = \text{Cov}(X, 1 - X) = \text{Cov}(X, -X) = -\text{Cov}(X, X) = -\sigma_X^2 = -\frac{1}{12}$$

# Algorytmika

## Ćwiczenia 4

May 7, 2025

**Adrian Herda**

Informatyka Algorytmiczna  
Politechnika Wrocławska

### 7. Zadanie 18

Lemat Schwartz-Zippela:

$$P \in R[x_1, \dots, x_n]$$

To niezerowy wielomian o stopniu całkowitym  $\deg(P) = d \geq 0$  nad domeną  $R$ . Jeśli  $S$  jest skończonym podzbiorem  $R$  to wybierając niezależnie i jednostajnie losowe  $r_1, \dots, r_n$  należące do  $S^n$

$$\Pr[P(r_1, \dots, r_n) = 0] \leq \frac{d}{|S|}$$

#### 7.1. Oszacowanie liczby zer

Niech  $f \in k[x_1, \dots, x_n]$  będzie wielomianem w którym każda zmienna występuje w stopniu co najwyżej  $d$ . Załóżmy, że  $f \neq 0$ , oraz  $A \subseteq k$  i  $|A| > d$ . Chcemy oszacować:

$$|\{a \in A^n : f(a) = 0\}| \leq d \cdot |A|^{n-1}$$

Z Lematu Schwartz-Zippela dla  $a \in A^n$ :

$$\frac{d}{|A|} \geq \Pr[f(a) = 0] = \frac{|\{a \in A^n : f(a) = 0\}|}{|A^n|}$$

mnożymy to przez  $|A^n| = |A|^n$

$\Downarrow$

$$|\{a \in A^n : f(a) = 0\}| \leq d \cdot |A|^{n-1}$$

#### 7.2. Prawdopodobieństwo dla $|A| = 2d$

Z Lematu Schwartz-Zippela wynika, że dla  $|A| = 2d$  mamy:

$$\Pr[f(\zeta) = 0] \leq \frac{d}{|A|} = \frac{d}{2d} = \frac{1}{2}$$

#### 7.3. Dla Ciągu Isoowych punktów

$|A| = 2d$  oraz  $\{\zeta_1, \dots, \zeta_{40}\} \subseteq A$  to ciąg niezależnych oraz losowych punktów ze zbioru  $A^n$ .

$$\forall_{n \in [40]} \Pr[f(\zeta_n) = 0] \leq \frac{1}{2}$$

Jako że  $\zeta$  są niezależne to:

$$\Pr[f(\zeta_1) = \dots = f(\zeta_{40}) = 0] = \Pr[f(\zeta_1) = 0] \cdot \dots \cdot \Pr[f(\zeta_{40}) = 0] \leq \left(\frac{1}{2}\right)^{40} < 10^{-12}$$

## 7.4. Zadanie 21

Rzucamy igłę długości  $l$  na płaszczyznę z pionowymi liniami równoległymi w odległościach  $k = 1$ .

Parametry:

- $t = 1$  - odległość między liniami
- $l \leq t$  - długość igły
- $x \sim U[0, \frac{t}{2}]$  - odległość środka igły od linii
- $\theta \sim U[0, \frac{\pi}{2}]$  - kąt nachylenia igły do poziomu

$$f_X(x) = \begin{cases} \frac{2}{t} : 0 \leq x \leq \frac{t}{2} \\ 0 : \text{gdziekolwiek indziej} \end{cases}$$

$$f_\Theta(\theta) = \begin{cases} \frac{2}{\pi} : 0 \leq \theta \leq \frac{\pi}{2} \\ 0 : \text{gdziekolwiek indziej} \end{cases}$$

$\Downarrow$

$$f_{X\Theta}(x, \theta) = f_X(x) \cdot f_\Theta(\theta) = \begin{cases} \frac{4}{\pi t} : 0 \leq x \leq \frac{t}{2}, 0 \leq \theta \leq \frac{\pi}{2} \\ 0 : \text{gdziekolwiek indziej} \end{cases}$$

Igła przecina linię, gdy:

$$x \leq \frac{l}{2} \cos \theta$$

Teraz liczymy prawdopodobieństwo:

$$\begin{aligned} \Pr[\text{Igła przecina linię}] &= \Pr\left[x \leq \frac{l}{2} \cos \theta\right] = \int_{\theta=0}^{\frac{\pi}{2}} \int_{x=0}^{\frac{l}{2} \cos \theta} f_{X\Theta}(x, \theta) dx d\theta = \\ &= \int_{\theta=0}^{\frac{\pi}{2}} \int_{x=0}^{\frac{l}{2} \cos \theta} \frac{4}{\pi t} dx d\theta = \int_0^{\frac{\pi}{2}} \left[\frac{4x}{\pi t}\right]_0^{\frac{l}{2} \cos \theta} d\theta = \frac{4l}{2\pi t} \int_0^{\frac{\pi}{2}} \cos \theta d\theta = \frac{2l}{\pi t} \cdot [\sin \theta]_0^{\frac{\pi}{2}} = 2 \frac{l}{\pi t} \end{aligned}$$

# Algorytmika

## Ćwiczenia 5

Adrian Herda

2025-06-28

### Zadanie 22

Zmienna losowa

$$L \sim \text{Uni}\{0, \dots, n-1\}$$

to znaczy że:

$$\Pr[L = k] = \frac{1}{n}, \text{ dla } 0 \leq k < n.$$

Zmienna losowa

$$X = \max\{L, n - L - 1\}$$

$$X = \begin{cases} L, & \text{jeśli } L > \frac{n-1}{2} \\ n - L - 1, & \text{jeśli } L \leq \frac{n-1}{2} \end{cases}$$

$$X = \begin{cases} k, & \text{jeśli } k > \frac{n-1}{2} \\ n - k - 1, & \text{jeśli } k \leq \frac{n-1}{2} \end{cases}$$

Dla  $n = 2m$  czyli parzystego mamy  $\frac{n-1}{2} = m - \frac{1}{2}$  wtedy:

$$\begin{aligned} \sum_{k=0}^{2m-1} \max\{k, 2m - k - 1\} &= \sum_{k=0}^{m-1} (2m - k - 1) + \sum_{k=m}^{2m-1} k = \\ \frac{m(2m-1+m)}{2} + \frac{m(m+2m-1)}{2} &= \frac{m(3m-1) + m(3m-1)}{2} = 3m^2 - m \end{aligned}$$

A więc wartość oczekiwana:

$$E(X) = \frac{1}{n} \sum_{k=0}^{2m-1} \max\{k, 2m - k - 1\} = \frac{1}{2m} \cdot (3m^2 - m) = \frac{3m-1}{2} = \frac{3}{4}n - \frac{1}{2}$$

Dla  $n = 2m + 1$  czyli parzystego mamy  $\frac{n-1}{2} = \frac{2m}{2} = m$  wtedy:

$$\begin{aligned} \sum_{k=0}^{2m} \max\{k, 2m - k\} &= \sum_{k=0}^m (2m - k) + \sum_{k=m+1}^{2m} k = \\ \frac{(m+1)(2m+m)}{2} + \frac{m(m+1+2m)}{2} &= \frac{3m^2 + 3m + 3m^2 + m}{2} = \frac{6m^2 + 4m}{2} = 3m^2 + 2m \end{aligned}$$

A więc wartość oczekiwana:

$$\begin{aligned} E(X) &= \frac{1}{n} \sum_{k=0}^{2m} \max\{k, 2m - k\} = \frac{m(3m+2)}{n} = \frac{(n-1) \cdot (3 \cdot (\frac{n-1}{2}) + 2)}{2n} = \\ &= \frac{(n-1) \cdot (3n+1)}{4n} = \frac{3n^2 - 2n - 1}{4n} \end{aligned}$$



# Algorytmika

## Ćwiczenia 6

May 28, 2025

**Adrian Herda**  
Politechnika Wrocławska

### 8. Zadanie 27

Niech  $X$  będzie licznikiem morrisa. Licznik rozpoczyna z wartością 0 i dla każdej operacji inkrementowany jest z prawdopodobieństwem  $2^{-X}$ . Estymator morrisa jest zdefiniowany jako:

$$\begin{aligned}\hat{n} &= 2^{X_n} - 1 \\ \hat{n} + 1 &= 2^{X_n}\end{aligned}$$

gdzie  $X_n$  jest licznikiem morrisa po  $n$  operacjach. Wartość oczekiwana tego estymatora jest równa:

$$E[\hat{n}] = n$$

Dowód przez indukcję:

1. Dla  $n = 0$  mamy  $E[\hat{n}] = 2^{X_0} - 1 = 2^0 - 1 = 0$ .
2. Załóżmy, że dla dowolnego  $n$  mamy  $E[\hat{n}] = n$ .
3. Dla  $n + 1$  mamy:

$$\begin{aligned}E[\widehat{n+1}] &= E[2^{X_{n+1}} - 1] \\ &= \sum_{i=1}^{\infty} P(X_n = i) \cdot E[2^{X_{n+1}} \mid X_n = i] - 1 \\ &= \sum_{i=1}^{\infty} P(X_n = i) \cdot \left( \underbrace{\frac{1}{2^i} \cdot 2^{i+1}}_{\text{increment}} + \underbrace{\left(1 - \frac{1}{2^i}\right) \cdot 2^i}_{\text{no increment}} \right) - 1 \\ &= \sum_{i=1}^{\infty} P(X_n = i) \cdot (2^i + 1) - 1 \\ &= \sum_{i=1}^{\infty} P(X_n = i) 2^i + \sum_{i=1}^{\infty} P(X_n = i) - 1 \\ &= E[2^{X_n}] + 1 - 1 \\ &= E[\hat{n} + 1] = n + 1\end{aligned}$$

■

### 8.1. Wariancja

$$\begin{aligned}
E[2^{2X_n}] &= \sum_{i=1}^{\infty} P(X_n = i) \cdot 2^{2i} \\
&= \sum_{i=1}^{\infty} \left( P(X_{n-1} = i-1) \cdot \frac{1}{2^{i-1}} + P(X_{n-1} = i) \cdot \left(1 - \frac{1}{2^{i-1}}\right) \right) \cdot 2^{2i} \\
&= \sum_{i=1}^{\infty} 2^{i+1} P(X_{n-1} = i-1) + \sum_{i=1}^{\infty} 2^{2i} P(X_{n-1} = i) - \sum_{i=1}^{\infty} 2^i P(X_{n-1} = i) \\
&= 4 \sum_{i=1}^{\infty} 2^{i-1} P(X_{n-1} = i-1) + E[2^{2X_{n-1}}] + E[2^{X_{n-1}}] \\
&= 4E[2^{X_{n-1}}] + E[2^{2X_{n-1}}] + E[2^{X_{n-1}}] \\
&= 3E[2^{X_{n-1}}] + E[2^{2X_{n-1}}] \\
&= 3n + E[2^{2X_{n-1}}]
\end{aligned}$$

Ta formuła jest rekurencyjna, więc możemy ją rozwinąć i otrzymamy ciąg arytmetyczny:

$$E[2^{2X_n}] = 1 + \sum_{i=1}^n 3i = 1 + \frac{3}{2}n(n+1)$$

A więc:

$$\begin{aligned}
\text{Var}(\hat{n}) &= E[(2^{X_n} - 1)^2] - E[2^{X_n} - 1]^2 \\
&= E[2^{2X_n} - 2 \cdot 2^{X_n} + 1] - n^2 \\
&= E[2^{2X_n}] + 1 - 2E[2^{X_n}] - n^2 \\
&= 1 + \frac{3}{2}n(n+1) + 1 - (2E[2^{X_n}] - 2) - n^2 - 2 \\
&= \frac{3}{2}n^2 + \frac{3}{2}n - (2E[2^{X_n} - 1]) - n^2 \\
&= \frac{3}{2}n^2 + \frac{3}{2}n - 2n - n^2 \\
&= \frac{1}{2}n^2 - \frac{1}{2}n \\
&= \frac{1}{2}n(n-1)
\end{aligned}$$

### 8.2. Błąd standardowy

Błąd standardowy estymatora Morrisa jest równy pierwiastkowi z wariancji podzielonej przez liczbę operacji:

$$\text{SE}[\hat{n}] = \sqrt{\text{Var}\left(\frac{\hat{n}}{n}\right)} = \sqrt{\frac{1}{2} \frac{n(n-1)}{n^2}} = \sqrt{\frac{n-1}{2n}}$$

## 9. Zadanie 28

Niech  $h(x)$  będzie funkcją hashującą, która dla każdego  $x$  zwraca wartość z tablicy hashującej o długości  $m$ .

$$P(\text{kolizja}) = P(\exists_{i \neq j} (h(x_i) = h(x_j)))$$

### 9.1. Dowód wzoru

Założmy że wstawione zostało już  $n$  elementów. To znaczy że pozostało  $m - n$  miejsc w tablicy hashującej. Prawdopodobieństwo kolizji przy wstawianiu następnego elementu  $x_{\{n+1\}}$  jest równe:

$$P(\text{kolizja}) = \frac{n}{m}$$

Przy wstawianiu kolejnych  $n$  elementów prawdopodobieństwo kolizji liczone jest w następujący sposób:

$$\left. \begin{aligned} P(\text{brak kolizji}) &= \prod_{i=0}^{n-1} \frac{m-i}{m} \approx \exp\left(-\frac{n(n-1)}{2m}\right) \\ \frac{1}{2} \leq P(\text{kolizja}) &\Rightarrow \frac{1}{2} \geq P(\text{brak kolizji}) \end{aligned} \right\} \Rightarrow \frac{1}{2} \approx \exp\left(-\frac{n(n-1)}{2m}\right)$$

$$\ln(2) \approx \frac{n(n-1)}{2m}$$

$$n(n-1) \approx 2 \ln(2)m$$

$$n^2 - n \approx 2 \ln(2)m$$

Dla dostatecznie dużych  $n$  możemy przyjąć, że

$$n^2 - n \approx n^2$$

więc:

$$n^2 \approx 2 \ln(2)m$$

$$n \approx \sqrt{2 \ln(2)m}$$

■

### 9.2. Wartość $n$ dla $m = 2^{16}$

$$\begin{aligned} n &\approx \sqrt{2 \ln(2) 2^{16}} \\ &\approx \sqrt{2 * 0.693147 * 65536} \\ &\approx \sqrt{90852.18725} \\ &\approx 301.417 \end{aligned}$$

## 10. Zadanie 29

Niech  $h_b(x)$  będzie funkcją skrótu zwracającą  $b$ -bitowe ciągi. Rozmiar przestrzeni obrazów funkcji  $h_b(x)$  dla dowolnego  $b$  wynosi:

$$|\{y : h_b(x) = y\}| = 2^b = m$$

Z poprzedniego zadania mamy wzór przybliżający wartość  $n$  dla której prawdopodobieństwo kolizji wynosi conajmniej  $\frac{1}{2}$ :

$$n \approx \sqrt{2m \ln(2)} = \sqrt{2 \cdot 2^b \cdot \ln(2)} = 2^{\frac{b}{2}} \cdot \sqrt{2 \ln(2)}$$

**10.1. Dla  $b = 64$**

$$n \approx 2^{\frac{64}{2}} \cdot \sqrt{2 \ln(2)} = 2^{32} \sqrt{2 \ln(2)} \approx 5.05694 \cdot 10^9$$

**10.2. Dla  $b = 128$**

$$n \approx 2^{\frac{128}{2}} \cdot \sqrt{2 \ln(2)} = 2^{64} \sqrt{2 \ln(2)} \approx 2.17194 \cdot 10^{19}$$

**10.3. Dla  $b = 256$**

$$n \approx 2^{\frac{256}{2}} \cdot \sqrt{2 \ln(2)} = 2^{128} \sqrt{2 \ln(2)} \approx 4.00652 \cdot 10^{38}$$

# Algorytmika

## Ćwiczenia 7

June 10, 2025

**Adrian Herda**

Informatyka Algorytmiczna

Politechnika Wrocławska

## 11. Zadanie 33 - wyznacznik Vandermonda

### 11.1. Treść

Pokazać że

$$V(x_1, \dots, x_n) = \prod_{i < j} (x_j - x_i)$$

### 11.2. Rozwiązanie

Macierz Vandermonda jest zdefiniowana jako:

$$\begin{pmatrix} 1 & x_0 & x_0^2 & \dots & x_0^n \\ 1 & x_1 & x_1^2 & \dots & x_1^n \\ 1 & x_2 & x_2^2 & \dots & x_2^n \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \dots & x_n^n \end{pmatrix}$$

A jej wyznacznik to

$$V(x_1, \dots, x_n) = \begin{vmatrix} 1 & x_0 & x_0^2 & \dots & x_0^n \\ 1 & x_1 & x_1^2 & \dots & x_1^n \\ 1 & x_2 & x_2^2 & \dots & x_2^n \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \dots & x_n^n \end{vmatrix}$$

**Główna idea dowodu:** Jeśli do kolumny macierzy dodamy (lub od niej odejmiemy) inną kolumnę pomnożoną przez pewien skalar, to wyznacznik macierzy nie zmienia się.

A więc w każdej kolumnie oprócz pierwszej odejmujemy poprzednią pomnożoną przez  $x_0$ . To daje nam macierz:

$$V = \begin{pmatrix} 1 & 0 & 0 & \dots & 0 \\ 1 & x_1 - x_0 & x_1(x_1 - x_0) & \dots & x_1^{n-1}(x_1 - x_0) \\ 1 & x_2 - x_0 & x_2(x_2 - x_0) & \dots & x_2^{n-1}(x_2 - x_0) \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n - x_0 & x_n(x_n - x_0) & \dots & x_n^{n-1}(x_n - x_0) \end{pmatrix}$$

Teraz wykonując rozwinięcie Laplace'a względem pierwszego wiersza otrzymujemy  $\det(V) = \det(B)$  gdzie:

$$B = \begin{pmatrix} x_1 - x_0 & x_1(x_1 - x_0) & \dots & x_1^{n-1}(x_1 - x_0) \\ x_2 - x_0 & x_2(x_2 - x_0) & \dots & x_2^{n-1}(x_2 - x_0) \\ \vdots & \vdots & \ddots & \vdots \\ x_n - x_0 & x_n(x_n - x_0) & \dots & x_n^{n-1}(x_n - x_0) \end{pmatrix}$$

Jako że wszystkie wartości na  $i$ -tym wierszu mają współczynnik w postaci  $x_{i+1} - x_0$  możemy je wyciągnąć przed macierz i otrzymać równość:

$$\begin{aligned} \det(V) &= (x_1 - x_0)(x_2 - x_0) \dots (x_n - x_0) \begin{vmatrix} 1 & x_1 & x_1^2 & \dots & x_1^{n-1} \\ 1 & x_2 & x_2^2 & \dots & x_2^{n-1} \\ 1 & x_3 & x_3^2 & \dots & x_3^{n-1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \dots & x_n^{n-1} \end{vmatrix} \\ &= \prod_{1 \leq i \leq n} (x_i - x_0) \det(V') \end{aligned}$$

gdzie  $V'$  jest macierzą Vandermonda dla  $x_1, \dots, x_n$ . powtarzając ten proces na coraz mniejszych macierzach Vandermonda otrzymujemy produkt:

$$\begin{aligned} \det(V) &= \prod_{0 \leq i \leq n} (x_i - x_0) \cdot \prod_{1 \leq i \leq n} (x_i - x_1) \cdot \dots \cdot \prod_{n-1 \leq i \leq n} (x_i - x_{n-1}) \\ &= \prod_{0 \leq j < n} \left( \prod_{j < i \leq n} (x_i - x_j) \right) \\ &= \prod_{0 \leq j < i \leq n} (x_i - x_j) \quad \begin{array}{l} \text{Zamieniając} \\ \text{notacje} \end{array} \quad i - j \\ &= \prod_{0 \leq i < j \leq n} (x_j - x_i) \end{aligned}$$

■

## 12. Zadanie 36 - maksymalne sparowanie dzięki specyfikacji

### 12.1. Treść

Należy udowodnić że jeśli w grafie  $G = (V, E)$  zachodzą warunki specyfikacji  $S$  albo *single* to zbiór  $M = \{(p, \text{pref}_p) : \text{pref}_p \neq \text{NULL}\}$  jest sparowaniem maksymalnym.

$$S = (\forall_{p \in V})(\text{married}(p) \vee \text{single}(p))$$

### 12.2. Dowód

Dowód będzie nie wprost

Założmy przeciwnie, że zbiór  $M$  nie jest maksymalnym sparowaniem, to znaczy że istnieje  $M'$  taki że  $M \subset M'$ .

1.  $M$  jest poprawnym sparowaniem. Z definicji *married*:

$$\text{married}(p) \equiv \text{pref}_p = q \in N(p) \wedge \text{pref}_q = p \in N(q)$$

Zatem jeśli  $\text{pref}_q \neq \text{NULL}$  to żeby dodać  $(p, \text{pref}_p)$  do  $M$ , musimy mieć:

- $\text{pref}_p = q$
- $\text{pref}_q = p$

A więc jako że każdy wierzchołek może być albo *married* albo *single* to żaden wierzchołek nie może być częścią obu par.

## 2. Załóżmy że $M$ nie jest maksymalne

Jako że  $M$  nie jest maksymalne to znaczy że istnieje para  $(p, q) \in M' \setminus M$  którą można by dodać do  $M$ . Oznacza to, że:

- $\text{pref}_p = \text{NULL}$ ,
- $\text{pref}_q = \text{NULL}$ ,
- $p \in N(q) \wedge q \in N(p)$ ,

To oznacza że oba wierzchołki są *free* co zaprzecza warunkom specyfikacji.

Zatem  $M$  musi być sparowaniem maksymalnym. ■

# 13. Zadanie 37 - specyfikacja kończy jakąkolwiek pracę w algorytmie

## 13.1. Treść

Należy udowodnić że jeśli zachodzą warunki specyfikacji  $S$  to konfiguracja jest ostateczna (żaden krok algorytmu nie zmieni konfiguracji)

$$S = (\forall_{p \in V})(\text{married}(p) \vee \text{single}(p))$$

### 13.1.1. Algorytm

```
do forever
  if pref_p == NULL && (exists q in N(p))(pref_q == p)
    pref_p ← q
  end if
  if pref_p == NULL
    && (forall q in N(p))(pref_q != p)
    && (exists q in N(p))(pref_q == NULL)
    pref_p ← q
  end if
  if pref_p == q && pref_q != p && pref_q != NULL
    pref_p ← NULL
  end if
end do
```

## 13.2. Dowód

Jeśli zachodzą warunki specyfikacji  $S$  to znaczy że nie ma żadnych wierzchołków w stanach *free*, *wait* oraz *chain*.

1. Pierwsza klauzula `if` sprawdza czy istnieje wierzchołek  $p$  taki że  $\text{pref}_p = \text{NULL}$  oraz istnieje wierzchołek  $q \in N(p)$  taki że  $\text{pref}_q = p$  a to znaczyłoby że wierzchołek  $q$  musi być w stanie *wait*. Jako że nie ma już takich wierzchołków dzięki warunkom specyfikacji, ta klauzula nie może zostać wykonana.
2. Druga klauzula `if` sprawdza istnienie wierzchołka  $p$  takiego że  $\text{pref}_p = \text{NULL}$  oraz takiego wierzchołka  $q \in N(p)$  że  $\text{pref}_q = \text{NULL}$ . Taka klauzula spełniona byłaby tylko gdyby  $\text{free}(p) \wedge \text{free}(q)$ . Jako że nie ma już takich wierzchołków dzięki warunkom specyfikacji, ta klauzula nie może zostać wykonana.
3. Trzecia klauzula `if` sprawdza istnienie wierzchołka  $p$  takiego że  $\text{pref}_p = q$  oraz takiego wierzchołka  $q \in N(p)$  że  $\text{pref}_q \neq p \wedge \text{pref}_q \neq \text{NULL}$  to znaczy że  $\text{pref}_q = r \wedge r \neq p$ . To znaczyłoby że raka klauzula byłaby spełniona tylko dla wierzchołka  $\text{chain}(p)$ . Jako że nie ma już takich wierzchołków dzięki warunkom specyfikacji, ta klauzula nie może zostać wykonana.

Z punktów powyższych klauzul wynika że algorytm nie może wykonać żadnego kroku, a więc konfiguracja jest ostateczna.

■